

| Datensatzverarbeitung<br>(engl. dataset pipeline)                                                                                                                                                  |  |                                                                                   |                                                                                   |                                                                                   |                                                 |                                                                                     |                                                                                     |                                                                                                                                                                                                     |                                                                                     |                                                                                     |                                           |                                                                                     |                                                  |                                                                                                                         |                                                                                                                                                                                                                                                                                                                                |                                                                                     |                                                                                     |                                                                    |  |                                                      |                                                    |                                                 |                                                          |  |  |  |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--|-----------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|-------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------|--|------------------------------------------------------|----------------------------------------------------|-------------------------------------------------|----------------------------------------------------------|--|--|--|
| Datensatzakquisition<br>(engl. dataset acquisition)                                                                                                                                                |  |                                                                                   |                                                                                   |                                                                                   | Datensatzsichtung<br>(engl. dataset inspection) |                                                                                     |                                                                                     |                                                                                                                                                                                                     |                                                                                     | Datensatzaufbereitung<br>(engl. dataset preparation)                                |                                           |                                                                                     |                                                  |                                                                                                                         |                                                                                                                                                                                                                                                                                                                                |                                                                                     |                                                                                     |                                                                    |  |                                                      |                                                    |                                                 |                                                          |  |  |  |
|                                                                                                                                                                                                    |  |                                                                                   |  |                                                                                   |                                                 |                                                                                     |                                                                                     |                                                                                                                                                                                                     |                                                                                     |  |                                           |                                                                                     |                                                  |                                                                                                                         |                                                                                                                                                                                                                                                                                                                                |                                                                                     |  |                                                                    |  |                                                      |                                                    |                                                 |                                                          |  |  |  |
| Datensatzrechenrche<br>(engl. dataset research)                                                                                                                                                    |  | Datensatzsammlung<br>(engl. dataset collection)                                   |                                                                                   | Datensatzprüfung<br>(engl. dataset check)                                         |                                                 | Datensatzauswahl<br>(engl. dataset selection)                                       |                                                                                     | Explorative Datenanalyse<br>(engl. exploratory data analysis)<br><br>In der EDA werden Textdaten untersucht, um Muster, Qualitätsprobleme und Strukturen zu erkennen.<br><br><i>(perplexity.ai)</i> |                                                                                     |                                                                                     |                                           |                                                                                     |                                                  |                                                                                                                         |                                                                                                                                                                                                                                                                                                                                |                                                                                     |                                                                                     | Datensatzbereinigung<br>(engl. dataset cleaning)                   |  |                                                      | Datensatzvalidierung<br>(engl. dataset validation) |                                                 |                                                          |  |  |  |
| Suchstrategie<br>(engl. search strategy)                                                                                                                                                           |  | Download<br>(engl. data download)                                                 | Speicherung<br>(engl. data storage)                                               | KI-Detektor<br>(engl. AI-Detector)                                                |                                                 | Score<br>(engl. dataset score)                                                      |                                                                                     | Datenstrukturanalyse<br>(engl. data structure analysis)                                                                                                                                             |                                                                                     | Dateninhaltsanalyse<br>(engl. data content analysis)                                |                                           |                                                                                     |                                                  |                                                                                                                         |                                                                                                                                                                                                                                                                                                                                |                                                                                     |                                                                                     |                                                                    |  | Fehlwertbehandlung<br>(engl. missing value handling) |                                                    | Duplikatentfernung<br>(engl. duplicate removal) |                                                          |  |  |  |
|                                                                                                                                                                                                    |  |                                                                                   |                                                                                   |                                                                                   |                                                 |                                                                                     |                                                                                     |                                                                                                                                                                                                     |                                                                                     | Analyse der strukturierten Daten<br>(engl. analysis of structured data)             |                                           |                                                                                     |                                                  | Fehlwertanalyse<br>(engl. missing value analysis)                                                                       |                                                                                                                                                                                                                                                                                                                                |                                                                                     | Analyse der unstrukturierten Daten<br>(engl. analysis of unstructured data)         |                                                                    |  |                                                      | Imputation<br>(engl. imputation)                   |                                                 | Listenweiser Fallausschluss<br>(engl. listwise deletion) |  |  |  |
|                                                                                                                    |  |  |  |  |                                                 |  |  |                                                                                                                                                                                                     |  |                                                                                     |                                           |  |                                                  |                                                                                                                         |                                                                                                                                                                                                                                                                                                                                |  |                                                                                     |                                                                    |  |                                                      |                                                    |                                                 |                                                          |  |  |  |
| Rohzeichenfolgen<br>(engl. raw strings)                                                                                                                                                            |  |                                                                                   |                                                                                   |                                                                                   |                                                 |                                                                                     |                                                                                     |                                                                                                                                                                                                     |                                                                                     |                                                                                     |                                           |                                                                                     |                                                  |                                                                                                                         |                                                                                                                                                                                                                                                                                                                                |                                                                                     |                                                                                     |                                                                    |  |                                                      |                                                    |                                                 |                                                          |  |  |  |
| Suchbegriffe<br><br>• „Beschwerden“<br>• „Kommentare“<br>• „NLP“<br>• „Kundenbeschwerden“<br>• „Online-Kommentare“<br>• „Produktbewertungen“<br><br>Anforderungen<br><br>• organischer Datensatzes |  | lokale Speicherung                                                                |                                                                                   |                                                                                   |                                                 |                                                                                     |                                                                                     | Ortsdaten<br>(engl. location data)                                                                                                                                                                  | Zeitdaten<br>(engl. time data)                                                      | Bewertungen<br>(engl. rating data)                                                  | Nummernfehlwerte<br>(engl. number errors) | Textfehlwerte<br>(engl. text errors)                                                | Duplikaterkennung<br>(engl. duplicate detection) | Textlängenanalyse<br>(engl. text length analysis)                                                                       | „Strategies for handling missing data in text include imputation where missing values are estimated based on existing data and removal where incomplete observations are excluded from the analysis. These strategies help in ensuring the completeness and integrity of the text data.“<br><br><i>(Upadhye, 2020, p. 207)</i> |                                                                                     |                                                                                     | Duplikate verzerren NLP-Modelle, daher müssen sie entfernt werden. |  |                                                      |                                                    |                                                 |                                                          |  |  |  |
|                                                                                                                                                                                                    |  |                                                                                   |                                                                                   |                                                                                   |                                                 |                                                                                     |                                                                                     | • Länder<br><br>• Bundesstaaten                                                                                                                                                                     | • Zeitraumbestimmung<br><br>• Datumsanalyse                                         |                                                                                     | • NaNs (Not a Number)                     | • NaTs (Not a Text)                                                                 |                                                  | • Beschwerdelängenanalyse (engl. complaint length analysis)<br><br>• Satzlängenanalyse (engl. sentence length analysis) |                                                                                                                                                                                                                                                                                                                                |                                                                                     |                                                                                     |                                                                    |  |                                                      |                                                    |                                                 |                                                          |  |  |  |