

Datensatzakquisition (engl. dataset acquisition)						Datensatzverarbeitung (engl. dataset pipeline)										Datensatzaufbereitung (engl. dataset preparation)			
																			
Datensatzrecherche (engl. dataset research)	Datensatzsammlung (engl. dataset collection)		Datensatzprüfung (engl. dataset check)		Datensatzauswahl (engl. dataset selection)	Explorative Datenanalyse (engl. exploratory data analysis)										Datensatzbereinigung (engl. dataset cleaning)			Datensatzvalidierung (engl. dataset validation)
						In der EDA werden Textdaten untersucht, um Muster, Qualitätsprobleme und Strukturen zu erkennen. <i>(perplexity.ai)</i>													
Suchstrategie (engl. search strategy)	Download (engl. data download)	Speicherung (engl. data storage)	Datenursprungsprüfung (engl. data provenance check)	Datenauthentizitätsprüfung (engl. data authenticity check)	Score (engl. dataset score)	Datenstrukturanalyse (engl. data structure analysis)		Dateninhaltsanalyse (engl. data content analysis)								Datenstrukturbehandlung (engl. data structure handling)	Dateninhaltsbehandlung (engl. data content handling)		
				KI-Detektor (engl. AI-Detector)		Datenformatanalyse (engl. data format analysis)	Datenschemaanalyse (engl. data schema analysis)	Datenerkundung (engl. data exploration)				Datenerkennung (engl. data detection)				Fehlwertbehandlung (engl. missing value handling)		Duplikatbehandlung (engl. duplicate handling)	
																			

Rohzeichenfolgen (engl. raw strings)																				
Suchbegriffe „Beschwerden“ „Kommentare“ „NLP“ „Kundenbeschwerden“ „Online-Kommentare“ „Produktbewertungen“ Anforderungen - organischer Datensatzes		lokale Speicherung						Analyse der strukturierten Daten (engl. analysis of structured data)			Analyse der unstrukturierten Daten (engl. analysis of unstructured data)		Fehlwerterkennung (engl. missing value detection)		Duplikaterkennung (engl. duplicate detection)		Imputation (engl. imputation)	Listenweiser Fallausschluss (engl. listwise deletion)	Duplikatentfernung (engl. duplicate removal)	
								Ortsdaten (engl. location data)	Zeitdaten (engl. time data)	Bewertungen (engl. rating data)	Textlängenanalyse (engl. text length analysis)	Textfehlwerte (engl. text errors)	Nummernfehlwerte (engl. number errors)			„Strategies for handling missing data in text include imputation where missing values are estimated based on existing data and removal where incomplete observations are excluded from the analysis. These strategies help in ensuring the completeness and integrity of the text data.“ <i>(Upadhye, 2020, p. 207)</i>		Duplikate verzerren NLP-Modelle, daher müssen sie entfernt werden.		
								- Länder - Bundesstaaten - Orte	- Zeitraumbestimmung - Datumsanalyse	Bewertungsverteilung	- Beschwerdelängenanalyse (engl. complaint length analysis) - Satzlängenanalyse (engl. sentence length analysis)	NaTs (Not a Text)	NaNs (Not a Number)	- Zeilenduplikate - Spaltenduplikate						